

Entrega 3 - Ciência de Dados

1. Introdução

O processo de Ciência de Dados do projeto CreditGuard AI teve como objetivo transformar dados financeiros brutos em informações estratégicas para apoio à recuperação de crédito, monitoramento da inadimplência e tomada de decisão gerencial.

A análise foi desenvolvida com Python, Pandas, Matplotlib e notebooks Jupyter. Essa camada analítica foi responsável por executar limpeza, padronização, análise exploratória, definição de métricas, geração de visualizações e classificação heurística de risco. Os resultados tratados foram posteriormente integrados ao PostgreSQL e consumidos pelo backend Node.js/Express, alimentando os KPIs, alertas, gráficos e insights exibidos no dashboard executivo.

Os dados utilizados foram fornecidos em dois datasets reais:

- cobranca_assessorias.csv: base de contratos enviados para assessorias de cobrança.
- fluxo_pagamentos.xlsx: histórico de parcelas, vencimentos e pagamentos.

Após a correção dos dados, a base consolidada passou a conter 10.000 contratos, 100.000 registros de pagamentos, 0 outliers de atraso e 9.987 alertas automáticos gerados por regras heurísticas. É importante destacar que o projeto não implementa modelo supervisionado de Machine Learning. A classificação de risco é feita por regras determinísticas, transparentes e auditáveis.

2. Base de Dados Utilizada

2.1 Dataset de Cobrança

Arquivo: data-science/cobranca_assessorias.csv

Características principais:

- 10.000 registros de contratos financeiros.
- Informações de assessoria responsável pela cobrança.
- Dias de atraso inicial do contrato.
- Valor inadimplente inicial.
- Status de cobrança.
- Score interno de risco.
- Região do cliente.

Principais campos utilizados:

Campo	Finalidade Analítica
ID_Contrato	Identificação única do contrato
Nome_Assessoria	Assessoria responsável pela cobrança
Data_Envio_Assessoria	Data de envio do contrato para cobrança
Dias_Em_Atraso_Inicial	Dias de atraso na entrada da base
Valor_Inadimplente_Inicial	Exposição financeira inicial do contrato
Status_Cobranca	Situação operacional do contrato
Score_Interno_Risco	Indicador interno de risco
Regiao_Cliente	Região geográfica do cliente

2.2 Dataset de Fluxo de Pagamentos

Arquivo: data-science/fluxo_pagamentos.xlsx

Características principais:

CreditGuard AI - Documentacao Academica

- 100.000 registros de pagamentos e parcelas.
- Histórico de vencimentos.
- Datas de pagamento.
- Valores de parcela.
- Valores efetivamente pagos.
- Formas de pagamento.
- Indicador de contemplação.

Principais campos utilizados:

Campo		Finalidade Analítica
ID_Pagamento		Identificação do pagamento
ID_Contrato		Chave de relacionamento com contratos
Numero_Parcela		Número da parcela
Data_Vencimento		Data prevista de vencimento
Data_Pagamento		Data efetiva de pagamento
Valor_Parcela		Valor esperado da parcela
Valor_Pago		Valor efetivamente pago
Forma_Pagamento		Canal de pagamento utilizado
Indicador_Contemplado		Indicação de contemplação

3. Processo Analítico Implementado

A etapa de Ciência de Dados foi organizada em três notebooks principais:

- 01_data_cleaning_real.ipynb: limpeza, padronização e validação dos dados.
- 02_eda_real.ipynb: análise exploratória, gráficos, KPIs e padrões.
- 03_business_rules_real.ipynb: regras heurísticas de risco e priorização.

Além dos notebooks, o script etl_real.py automatiza a geração dos datasets limpos e do arquivo database/seed_real.sql, utilizado para carregar o PostgreSQL com os dados tratados.

Fluxo implementado:

CSV/XLSX -> Python/Pandas -> limpeza e validação -> notebooks -> seed_real.sql -> PostgreSQL -> APIs -> dashboard

3.1 Processamento e Limpeza dos Dados (Data Cleaning)

O processo de limpeza foi executado no notebook 01_data_cleaning_real.ipynb e consolidado no script etl_real.py.

Durante a leitura inicial, foram identificados:

- Contratos originais: (10000, 8).
- Pagamentos originais: (100000, 9).
- Scores internos nulos: 300.
- Duplicatas em pagamentos: 0.
- Parcelas não pagas: 27.357.

Trecho de leitura e validação inicial:

```
contratos = pd.read_csv(cobranca_path, encoding='latin1')
pagamentos = pd.read_excel(pagamentos_path)

print(f"Contratos originais: {contratos.shape}")
print(f"Pagamentos originais: {pagamentos.shape}")
```

Tratamentos Aplicados

Etapa		Tratamento Realizado		Resultado
Encoding		Leitura explícita da base CSV em latin1		Dados carregados sem perda estrutural

CreditGuard AI - Documentação Acadêmica

Padronização textual | Normalização de assessorias e regiões | 4 assessorias e 5 regiões padronizadas

Conversão monetária | Conversão de valores em formato textual para número | Média de R\$ 6.230,88 por contrato

Scores nulos | Imputação pela mediana | 300 nulos reduzidos para 0

Duplicatas | Verificação em pagamentos | 0 duplicatas removidas

Datas | Conversão de vencimento e pagamento para formato de data | Base apta a cálculo de aging

Outliers de atraso | Valores fora de 0 a 365 dias substituídos pela mediana válida | 80 outliers tratados

Tratamento de Outliers

O principal ajuste técnico da base foi o tratamento dos outliers de atraso. Foram encontrados 80 registros inválidos no campo `Dias_Em_Atraso_Inicial`:

Tipo de Outlier | Quantidade | Valor Original

Atraso negativo | 50 | -999 dias

Atraso extremamente elevado | 30 | 9999 dias

Esses valores não representam situações operacionais plausíveis. Para preservar os 10.000 contratos sem excluir registros da amostra, os atrasos fora do intervalo operacional de 0 a 365 dias foram substituídos pela mediana dos atrasos válidos, igual a 89 dias. A mediana foi escolhida por ser robusta a valores extremos e por manter a tendência central da base sem distorcer os KPIs.

Resultado após a limpeza:

- Contratos limpos: 10.000.
- Pagamentos limpos: 100.000.
- Outliers remanescentes: 0.
- Atraso mínimo: 15 dias.
- Atraso máximo: 207 dias.
- Atraso médio inicial pós-limpeza: 89,65 dias.

3.2 Execução da Análise Exploratória de Dados


A análise exploratória foi desenvolvida no notebook `02_eda_real.ipynb`, utilizando os arquivos `limpos_contratos_clean.csv` e `pagamentos_clean.csv`.

As análises realizadas incluíram:

- Distribuição regional da inadimplência.
- Concentração financeira por assessoria.
- Evolução temporal de parcelas pagas e abertas.
- Frequência de atrasos.
- Distribuição dos níveis de risco.
- Volume financeiro recuperado.
- Comparação entre valor inadimplente dos contratos e parcelas vencidas não pagas.
- Desempenho operacional das assessorias de cobrança.

Figura 1 - Inadimplência Monitorada por Região

CreditGuard AI - Documentacao Academica



A Figura 1 apresenta a inadimplência monitorada no nível de parcelas vencidas e não pagas. Essa é a métrica operacional exibida no dashboard. A região Nordeste concentra o maior volume, com R\$ 7.686.150,00, seguida pelo Sudeste, com R\$ 7.260.950,00.

Região | Inadimplência Monitorada

Nordeste | R\$ 7.686.150,00


Sudeste | R\$ 7.260.950,00

Sul | R\$ 3.116.950,00

Centro-Oeste | R\$ 1.592.000,00

Norte | R\$ 965.350,00


Figura 2 - Evolução Temporal de Parcelas Pagas e Abertas



CreditGuard AI - Documentacao Academica

A Figura 2 demonstra o comportamento mensal dos valores de parcelas pagas e abertas. Essa visualização permite acompanhar tendências de recuperação financeira e observar a formação da inadimplência ao longo do tempo.

Figura 3 - Distribuição Heurística de Risco



A Figura 3 representa a distribuição dos contratos após aplicação das regras heurísticas de risco. A concentração em risco alto indica que a carteira analisada possui perfil crítico, exigindo priorização operacional.

Nível de Risco | Quantidade | Percentual


Alto | 8.958 | 89,58%

Médio | 1.014 | 10,14%

Baixo | 28 | 0,28%

Figura 4 - Taxa de Acordo por Assessoria

CreditGuard AI - Documentacao Academica



A Figura 4 compara a taxa de acordo das assessorias. A assessoria Acerta Credito Integrado apresentou a maior taxa de acordo, com aproximadamente 35,05%, apesar de possuir menor volume de contratos em comparação com Fenix e Vertice.

Assessoria	Contratos	Acordos	Taxa de Acordo
Fenix Recuperacao de Credito	3.034	1.014	33,42%
Vertice Asset e Cobranca	3.003	1.022	34,03%
Nexus Mediacao Financeira	2.037	696	34,17%
Acerta Credito Integrado	1.926	675	35,05%

3.3 Definição de Métricas de Desempenho (KPIs)

Os KPIs foram definidos para medir inadimplência, recuperação, aging, risco e concentração regional. Um ponto essencial da correção foi separar duas métricas financeiras que antes apareciam misturadas.

Dicionário Oficial de KPIs

KPI	Fórmula	Valor Atual	Interpretação
Valor inadimplente dos contratos	SUM(Valor_Inadimplente_Inicial)	R\$ 62.308.840,80	Exposição financeira inicial no nível de contrato
Inadimplência monitorada	SUM(valor_parcela) de parcelas vencidas e não pagas	R\$ 20.621.400,00	Valor operacional em aberto exibido no dashboard
Taxa de recuperação	Parcelas vencidas pagas com atraso / parcelas vencidas	25,50%	Eficiência de recuperação da carteira
Recuperação no mês	SUM(valor_pago) de pagamentos atrasados no mês de referência	R\$ 1.431.904,74	Valor recuperado no período
Atraso médio inicial	AVG(Dias_Em_Atraso_Inicial) após limpeza	89,65 dias	Atraso médio na entrada do contrato
Aging operacional	Média de dias entre data de referência e vencimento de parcelas abertas	223,86 dias	Envelhecimento médio das parcelas vencidas não pagas
Clientes críticos	Contratos com alerta de nível Alto	8.958	Volume priorizado para cobrança
Contratos com atraso superior a 90 dias	Contratos com parcelas abertas acima de 90 dias	8.862	Carteira crítica por aging de parcelas
Alertas automáticos	Registros criados na tabela alertas_risco	9.987	Contratos sinalizados pelo motor heurístico

Diferença entre R\$ 62,3 mi e R\$ 20,6 mi

O valor de R\$ 62.308.840,80 representa a exposição dos contratos no momento em que entraram na base de cobrança. Já o valor de R\$ 20.621.400,00 representa apenas as parcelas vencidas e não pagas na data de referência da base, sendo a métrica operacional exibida pelo dashboard.

Essas métricas não são contraditórias. Elas respondem perguntas diferentes:


- Quanto a carteira expõe no nível de contrato? R\$ 62,3 milhões.
- Quanto está vencido e não pago no nível de parcela? R\$ 20,6 milhões.

3.4 Mapeamento de Padrões Identificados na Base

A análise exploratória permitiu identificar padrões importantes para o negócio:

- A inadimplência monitorada está concentrada nas regiões Nordeste e Sudeste.
- A região Nordeste responde por aproximadamente 37,3% do valor em aberto monitorado.
- O Sudeste também apresenta volume elevado, com R\$ 7,26 milhões em parcelas vencidas e não pagas.
- A carteira possui alta concentração de contratos classificados como risco alto: 8.958 contratos.
- Contratos com atraso inicial superior a 60 dias, status ajuizado ou score acima de 70 são os principais responsáveis pela geração de risco alto.
- 4.014 contratos permanecem com status "Em Aberto", equivalentes a 40,1% da carteira.
- 8.862 contratos possuem parcelas com atraso superior a 90 dias.
- A assessoria Acerta Credito Integrado apresenta a maior taxa de acordo, com 35,05%.
- A região Norte possui o maior ticket médio de inadimplência por contrato: R\$ 6.505,20.

Figura 5 - Valor Inadimplente dos Contratos por Região



A Figura 5 apresenta a exposição financeira no nível de contrato. Essa visão complementa a inadimplência monitorada por parcela e ajuda a dimensionar a carteira sob responsabilidade das assessorias.

Região | Valor Inadimplente dos Contratos
Nordeste | R\$ 22.748.368,22

Sudeste | R\$ 21.556.882,87
Sul | R\$ 9.828.722,06
Centro-Oeste | R\$ 5.026.348,66
Norte | R\$ 3.148.518,99

3.5 Extração de Insights Acionáveis para o Negócio

Com base nos padrões encontrados, foram definidos insights acionáveis para apoiar diretoria, financeiro e operação de cobrança.

Insight 1 - Priorizar Nordeste e Sudeste

As regiões Nordeste e Sudeste concentram juntas mais de R\$ 14,9 milhões em parcelas vencidas e não pagas. Isso indica que campanhas de cobrança, renegociação e acompanhamento gerencial devem começar por essas regiões.

Insight 2 - Atuar sobre a carteira crítica

O sistema identificou 8.958 contratos de risco alto e 8.862 contratos com parcelas acima de 90 dias de atraso. Esses contratos devem ser priorizados pela operação de cobrança, pois representam maior probabilidade de perda financeira e menor eficiência de recuperação espontânea.

Insight 3 - Usar performance das assessorias como critério de gestão

A taxa de acordo por assessoria permite comparar desempenho operacional. A Acerta Credito Integrado apresentou a maior taxa de acordo, enquanto Fenix e Vertice concentram maior volume de contratos. Esse cruzamento apoia decisões de redistribuição de carteira, metas e acompanhamento de produtividade.

Insight 4 - Separar exposição de contrato e valor vencido

A exposição total de contratos é de R\$ 62,3 milhões, enquanto a inadimplência operacional monitorada é de R\$ 20,6 milhões. Essa distinção evita interpretações incorretas e permite decisões mais precisas: diretoria acompanha exposição, enquanto cobrança atua sobre parcelas vencidas e não pagas.

Insight 5 - Manter regras transparentes

Como o sistema utiliza regras heurísticas, cada classificação pode ser explicada. Isso aumenta a auditabilidade e facilita a defesa da solução em ambiente acadêmico e corporativo.

4. Regras Heurísticas de Negócio

As regras de negócio foram implementadas no notebook 03_business_rules_real.ipynb e no ETL.

Trecho conceitual:

```
if dias > 60 or status == 'Ajuizado' or score > 70:  
    return 'Alto'  
elif dias > 15 or status == 'Insucesso':  
    return 'Medio'  
else:  
    return 'Baixo'
```

Classificação utilizada:

Nível	Critério
Baixo	Atraso inicial até 15 dias, sem indicadores críticos adicionais
Médio	Atraso entre 16 e 60 dias ou status de insucesso
Alto	Atraso superior a 60 dias, status ajuizado ou score interno acima de 70

CreditGuard AI - Documentação Acadêmica

Essas regras geraram 9.987 alertas automáticos:

Nível do Alerta | Quantidade
Alto | 8.958
Médio | 1.014
Baixo | 15

A diferença entre 28 contratos de risco baixo e 15 alertas de risco baixo ocorre porque nem todo contrato de baixo risco gera alerta na tabela operacional. A distribuição de risco avalia todos os contratos; a tabela de alertas registra apenas contratos sinalizados pelo motor operacional.

5. Integração com o Sistema

Após o tratamento, os dados foram integrados ao banco PostgreSQL por meio do arquivo `database/seed_real.sql`, gerado automaticamente pelo pipeline.

Fluxo de integração:

```
data-science/cobranca_assessorias.csv  
data-science/fluxo_pagamentos.xlsx  
v  
data-science/etl_real.py  
v  
database/seed_real.sql  
v  
PostgreSQL -> Backend Node.js -> Frontend React
```

O backend consome os dados por consultas SQL agregadas no serviço `kpiService.js`, garantindo que os indicadores do dashboard sejam calculados diretamente a partir do banco atualizado.

6. Ferramentas Utilizadas

Ferramenta | Finalidade
Python | Processamento e automação do pipeline
Pandas | Limpeza, transformação e análise dos datasets
Matplotlib | Geração de gráficos analíticos
Jupyter Notebook | Documentação executável da análise
PostgreSQL | Armazenamento relacional e analítico
Node.js/Express | APIs REST e cálculo de KPIs
React | Dashboard executivo
Recharts | Visualização interativa no frontend
Supabase | Hospedagem PostgreSQL

7. Conclusão

A Entrega 3 consolidou a etapa de Ciência de Dados do CreditGuard AI. O processo permitiu transformar dados financeiros brutos em datasets limpos, métricas confiáveis, visualizações exploratórias, regras heurísticas e insights acionáveis.

Os principais resultados foram:

- Tratamento de 80 outliers de atraso.
- Geração de base limpa com 10.000 contratos e 100.000 pagamentos.
- Definição de KPIs oficiais e separação entre exposição de contrato e inadimplência de parcelas.
- Identificação de 8.958 contratos de risco alto.
- Geração de 9.987 alertas automáticos.
- Produção de figuras e análises utilizadas pelo dashboard executivo.

Assim, a camada de Ciência de Dados passou a sustentar tecnicamente os módulos de backend, banco de dados, dashboard e inteligência analítica da solução.