

Entrega 3 - Ciência de Dados e Modelagem Preditiva

1. Processo de Limpeza de Dados (Data Cleaning)

A base real fornecida compunha-se de dois datasets:

- cobranca_assessorias.csv: 10.000 registros de contratos.
- fluxo_pagamentos.xlsx: 100.000 registros de trilha de pagamentos (histórico).

Tratamento realizado (01_data_cleaning_real.ipynb):

- Padronização Strings: Nomes de assessorias possuíam erros de trailing spaces e variações na capitalização. Foram aplicados métodos de expressão regular via Pandas (`str.lower()`, `str.contains()`) para unificar as 4 assessorias principais.
- Parsing Monetário: A coluna `Valor_Inadimplente_Inicial` continha símbolos "R\$" e formatação PT-BR (vírgula decimal). Construímos uma heurística de substituição para garantir floats puros.
- Datas: Tratamento dos timestamps com `pd.to_datetime(errors='coerce')` para lidar com eventuais erros de digitação na captura.

2. Análise Exploratória de Dados (EDA)

Através do script `02_eda_real.ipynb`, utilizando Matplotlib, geramos visualizações da concentração do risco geográfico.

- A região Nordeste apresentou-se como líder absoluta da inadimplência (R\$ 7.6 milhões), seguida do Sudeste (R\$ 7.2 milhões).

O sistema adota um conjunto de indicadores:

- Inadimplência Total (R\$): Acumulado financeiro das parcelas em aberto.
- Taxa de Recuperação (%): Aferida pela divisão do montante atrasado recebido vs. total da dívida. Atualmente o motor capturou ~25,4% de recuperação.
- Contratos Críticos: Identificam volumetria absoluta de clientes na faixa alarmante (>90 dias de atraso). (Identificados: 8.862 contratos).

4. Algoritmos Heurísticos e Regras de Negócio

No notebook `03_business_rules_real.ipynb`, estipulamos uma matriz de risco automatizada, injetando alertas de sistema baseados em três colunas simultâneas:

- Risco Alto: `Dias Atraso > 60 OU Status Cobrança == 'Ajuizado' OU Score Risco > 70`.

O endpoint do backend traduziu os dados do Data Science em linguagem natural para apoio à decisão:

- Concentração: O Nordeste é responsável por 37.3% de todo o débito na carteira.
- Performance de Assessoria: A "Acerta Credito Integrado" gerou a maior taxa de resolução, revertendo 35% de sua carteira alocada em acordos.

CreditGuard AI - Documentacao Academica

- Custo Regional: O ticket médio da inadimplência não está na região de maior volume, e sim na Região Norte (R\$ 6.505,20 por contrato isolado).

Gerado automaticamente pelo sistema de documentação analítica do CreditGuard AI.